

Исследование коэффициентов корреляции

Постановка задачи

- Генерация данных:** Сгенерировать две независимые выборки объемом 1000: $X \sim N(0; 1)$ и $Z \sim N(5; 2)$.
- Расчет зависимостей:** Для каждой пары (x, z) вычислить y тремя способами:
 - Линейная зависимость:** $Y = aX + (1 - a)Z$ для $a \in \{0, 0.25, 0.5, 0.75, 1\}$
 - Кубическая зависимость:** $Y = 0.05X^3 + 4Z$.
 - Квадратичная зависимость:** $Y = X^2 + Z$.
- Анализ выбросов:** Добавить аномальные значения к линейной (при $a = 0.5$) и кубической зависимостям. Проанализировать влияние выбросов на значения коэффициентов.
- Статистический анализ:** Для всех трех зависимостей (до и после добавления выбросов) рассчитать коэффициенты корреляции Пирсона, Спирмена и Кендалла. Проверить гипотезу о равенстве коэффициентов нулю на уровне значимости $\alpha = 0.05$.

Теоретическая часть

Коэффициент корреляции Пирсона

Измеряет силу и направление **линейной** связи между двумя непрерывными переменными:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- Интервал:** $[-1, 1]$.
- $r = 1$ — строгая прямая линейная связь.
- $r = 0$ — отсутствие линейной связи (при этом нелинейная зависимость может существовать).

Коэффициент корреляции Спирмена

Ранговый коэффициент, оценивающий, насколько хорошо связь между переменными может быть описана с помощью **монотонной** функции:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

где d_i — разность между рангами x_i и y_i . В отличие от коэффициента Пирсона, он устойчив к нелинейным монотонным преобразованиям и менее чувствителен к выбросам.

Коэффициент корреляции Кендалла (τ)

Основан на подсчете количества согласованных (n_c) и несогласованных (n_d) пар наблюдений. Считается наиболее **робастным** (устойчивым к аномалиям) методом:

$$\tau = \frac{n_c - n_d}{\frac{1}{2}n(n - 1)}$$

Коэффициент Кендалла эффективен при небольших выборках и наличии большого количества совпадающих рангов.

Проверка гипотезы о значимости корреляции

Для проверки гипотезы H_0 : коэффициент = 0 (отсутствие связи) используется значение p -value.

- При уровне значимости $\alpha = 0.05$ гипотеза H_0 отвергается, если $p\text{-value} < 0.05$. В этом случае связь признается статистически значимой.

```
In [71]: import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Устанавливаем seed для воспроизводимости результатов
np.random.seed(42)
```

1. Генерация независимых выборок

Генерируем две независимые выборки размером 1000:

- X подчиняется нормальному распределению $N(0,1)$ - стандартное нормальное
- Z подчиняется нормальному распределению $N(5,2)$ - среднее 5, стандартное отклонение $\sqrt{2}$

```
In [72]: # А. Генерация выборок
np.random.seed(42)
n = 1000
X = np.random.normal(0, 1, n)
```

```
Z = np.random.normal(5, 2, n) # Используем std=2

print(f"Размер выборки: {n}")
print(f"X: среднее={X.mean():.3f}, std={X.std():.3f}")
print(f"Z: среднее={Z.mean():.3f}, std={Z.std():.3f}")
```

Размер выборки: 1000
X: среднее=0.019, std=0.979
Z: среднее=5.142, std=1.994

```
In [ ]: def add_outliers(data, count=5):
    data_with_outliers = data.copy()
    idx = np.random.choice(n, count, replace=False)
    data_with_outliers[idx] = data_with_outliers[idx] + 50
    return data_with_outliers
```

2. Вычисление Y для трёх типов зависимостей

Для каждой пары (x,z) вычисляем Y по трём зависимостям:

1. **Линейная зависимость:** $Y = aX + (1-a)Z$

- Параметр a контролирует вес X и Z
- При a=0: Y=Z (полностью зависит от Z)
- При a=1: Y=X (полностью зависит от X)
- При a=0.5: равный вес обоих переменных

2. **Кубическая зависимость:** $Y = 0.05X^3 + 4Z$

- Нелинейная связь с X
- Квадратичный коэффициент перед X^3 ослабляет влияние нелинейности

3. **Квадратичная зависимость:** $Y = X^2 + Z$

- Нелинейная связь с X через квадрат
- Прямое влияние Z

```
In [ ]: Y_cases = {}

# Линейные зависимости
for a in [0, 0.25, 0.5, 0.75, 1.0]:
    Y_cases[f'Linear (a={a})'] = a * X + (1 - a) * Z

# Кубическая зависимость
Y_cases['Cubic'] = 0.05 * (X**3) + 4 * Z

# Квадратичная зависимость
Y_cases['Quadratic'] = (X**2) + Z
```

3. Добавление выбросов

Добавляем выбросы к выбранным зависимостям для анализа их влияния на коэффициенты корреляции:

- K B1 (линейная зависимость с a=0.5)

- К В2 (кубическая зависимость)

Выбросы добавляются путём изменения нескольких значений Y на экстремально большие значения.

```
In [75]: Y_cases['Linear (a=0.5) + Outliers'] = add_outliers(Y_cases['Linear (a=0.5)'])
Y_cases['Cubic + Outliers'] = add_outliers(Y_cases['Cubic'])

print("Данные для всех сценариев (включая выбросы) подготовлены.")
```

Данные для всех сценариев (включая выбросы) подготовлены.

4. Расчет коэффициентов корреляции и проверка гипотез

Для каждой зависимости рассчитываем три коэффициента корреляции:

1. Корреляция Пирсона (r): Мера линейной связи

- Диапазон: [-1, 1]
- Чувствительна к выбросам
- Наиболее известный и часто используемый

2. Ранговая корреляция Спирмана (ρ): Мера монотонной связи

- Основана на рангах данных
- Более устойчива к выбросам, чем Пирсона
- Хороша для нелинейных зависимостей

3. Коэффициент Кендалла (τ): Мера ранговой согласованности

- На основе пар согласованных и несогласованных наблюдений
- Самый устойчивый к выбросам
- Имеет лучшую статистическую интерпретацию

Для каждого коэффициента проверяем гипотезу $H_0: r=0$ ($\rho=0$, $\tau=0$) на уровне значимости $\alpha=0.05$.

```
In [76]: def get_stats(x, y):
r_p, p_p = stats.pearsonr(x, y)
r_s, p_s = stats.spearmanr(x, y)
r_k, p_k = stats.kendalltau(x, y)

format_p = lambda p: "< 0.001" if p < 0.001 else f"{p:.4f}"

return r_p, format_p(p_p), r_s, format_p(p_s), r_k, format_p(p_k)
```

```
In [77]: # ЛИНЕЙНАЯ ЗАВИСИМОСТЬ
print("Линейная зависимость Y = aX + (1 - a)Z")
a_values = [0, 0.25, 0.5, 0.75, 1.0]

for a in a_values:
    key = f"Linear (a={a})"
    if key in Y_cases:
        rp, pp, rs, ps, rk, pk = get_stats(X, Y_cases[key])
```

```
mini_df = pd.DataFrame([
    ["Пирсон", round(rp, 4), pp],
    ["Спирмен", round(rs, 4), ps],
    ["Кендалл", round(rk, 4), pk]
], columns=['Критерий', 'Коэффициент', 'p-value'])

print(f"\nПараметр a = {a}")
display(mini_df)
```

Линейная зависимость $Y = aX + (1 - a)Z$

Параметр $a = 0$

	Критерий	Коэффициент	p-value
0	Пирсон	-0.0404	0.2018
1	Спирмен	-0.0638	0.0438
2	Кендалл	-0.0438	0.0380

Параметр $a = 0.25$

	Критерий	Коэффициент	p-value
0	Пирсон	0.1224	< 0.001
1	Спирмен	0.0909	0.0040
2	Кендалл	0.0601	0.0044

Параметр $a = 0.5$

	Критерий	Коэффициент	p-value
0	Пирсон	0.4110	< 0.001
1	Спирмен	0.3793	< 0.001
2	Кендалл	0.2580	< 0.001

Параметр $a = 0.75$

	Критерий	Коэффициент	p-value
0	Пирсон	0.8201	< 0.001
1	Спирмен	0.8098	< 0.001
2	Кендалл	0.6132	< 0.001

Параметр $a = 1.0$

	Критерий	Коэффициент	p-value
0	Пирсон	1.0	< 0.001
1	Спирмен	1.0	< 0.001
2	Кендалл	1.0	< 0.001

Линейная зависимость $Y = aX + (1 - a)Z$

- При $a = 0$ ($Y = Z$) теоретически корреляция между X и Y должна отсутствовать. Коэффициент Пирсона подтверждает это, являясь статистически незначимым ($p\text{-value} > 0.05$).
- С ростом параметра a (увеличением доли X в итоговой выборке) все три коэффициента корреляции монотонно увеличиваются.
- При $a = 1$ ($Y = X$) наблюдается идеальная функциональная связь, при которой все коэффициенты корреляции принимают значение 1.0.
- На уровне значимости $\alpha = 0.05$ гипотеза H_0 об отсутствии связи отвергается для всех случаев, кроме $a = 0$.

```
In [78]: # КВАДРАТИЧНАЯ ЗАВИСИМОСТЬ
print("\nКвадратичная зависимость Y = X^2 + Z")
if 'Quadratic' in Y_cases:
    rp, pp, rs, ps, rk, pk = get_stats(X, Y_cases['Quadratic'])
    df_tab3 = pd.DataFrame([
        ["Пирсон", round(rp, 4), pp],
        ["Спирмен", round(rs, 4), ps],
        ["Кендалл", round(rk, 4), pk]
    ], columns=['Критерий', 'Коэффициент', 'p-value'])
    display(df_tab3)
```

Квадратичная зависимость $Y = X^2 + Z$

	Критерий	Коэффициент	p-value
0	Пирсон	0.0282	0.3729
1	Спирмен	-0.0221	0.4847
2	Кендалл	-0.0194	0.3583

Квадратичная зависимость $Y = X^2 + Z$

- Коэффициенты Пирсона, Спирмена и Кендалла близки к нулю, статистическая значимость отсутствует.
- **Причина:** Отсутствие корреляции объясняется немонотонным характером зависимости X^2 (функция убывает при $X < 0$ и возрастает при $X > 0$). Поскольку X распределено симметрично относительно нуля, положительная и отрицательная корреляции «взаимно уничтожаются».
- **Вывод:** Отсутствие линейной или ранговой корреляции не означает отсутствия зависимости между переменными.

```
In [79]: # КУБИЧЕСКАЯ ЗАВИСИМОСТЬ
print("\nКубическая зависимость Y = 0.05X^3 + 4Z")
if 'Cubic' in Y_cases:
    rp, pp, rs, ps, rk, pk = get_stats(X, Y_cases['Cubic'])
    df_tab2 = pd.DataFrame([
        ["Пирсон", round(rp, 4), pp],
        ["Спирмен", round(rs, 4), ps],
        ["Кендалл", round(rk, 4), pk]
    ], columns=['Критерий', 'Коэффициент', 'p-value'])
    display(df_tab2)
```

Кубическая зависимость $Y = 0.05X^3 + 4Z$

	Критерий	Коэффициент	p-value
0	Пирсон	-0.0223	0.4805
1	Спирмен	-0.0500	0.1144
2	Кендалл	-0.0346	0.1011

Кубическая зависимость $Y = 0.05X^3 + 4Z$

- Все коэффициенты корреляции близки к нулю ($|r| < 0.05$), а значение $p\text{-value} > 0.05$ во всех случаях. Гипотеза об отсутствии корреляции не отвергается.
- **Причина:** Несмотря на наличие математической зависимости, «сигнал» $0.05X^3$ крайне слаб и полностью маскируется сильным шумом Z с большой дисперсией. В данных условиях стандартные методы не фиксируют нелинейную связь.

```
In [ ]: def get_full_analysis(x, y):
    r_p, p_p = stats.pearsonr(x, y)
    r_s, p_s = stats.spearmanr(x, y)
    r_k, p_k = stats.kendalltau(x, y)

    f_p = lambda p: "< 0.001" if p < 0.001 else f"{p:.4f}"
    check_h0 = lambda p: "Отвергается" if p < 0.05 else "Не отвергается"

    return [
        [round(r_p, 4), f_p(p_p), check_h0(p_p)],
        [round(r_s, 4), f_p(p_s), check_h0(p_s)],
        [round(r_k, 4), f_p(p_k), check_h0(p_k)]
    ]

print("Анализ влияния выбросов на статистическую значимость")

# Список пар для сравнения: (Ключ_БЕЗ_выбросов, Ключ_С_выбросами, Название)
comparison_cases = [
    ('Linear (a=0.5)', 'Linear (a=0.5) + Outliers', 'Линейная зависимость (a=0.5)'),
    ('Cubic', 'Cubic + Outliers', 'Кубическая зависимость')
]

for base_key, outlier_key, title in comparison_cases:
    if base_key in Y_cases and outlier_key in Y_cases:
        print(f"\n--- {title} ---")

        base_stats = get_full_analysis(X, Y_cases[base_key])
        outlier_stats = get_full_analysis(X, Y_cases[outlier_key])

        df_impact = pd.DataFrame({
            "Критерий": ["Пирсон", "Спирмен", "Кендалл"],
            "Коэфф. (Без)": [base_stats[0][0], base_stats[1][0], base_stats[2][0]],
            "Н0 (Без)": [base_stats[0][2], base_stats[1][2], base_stats[2][2]],
            "Коэфф. (Выбросы)": [outlier_stats[0][0], outlier_stats[1][0], outlier_stats[2][0]],
            "Н0 (Выбросы)": [outlier_stats[0][2], outlier_stats[1][2], outlier_stats[2][2]]
        })

        df_impact['Изменение %'] = ((df_impact['Коэфф. (Выбросы)'] - df_impact['Коэфф. (Без)']) / df_impact['Коэфф. (Без)']) * 100
```

```
display(df_impact)
```

Анализ влияния выбросов на статистическую значимость

--- Линейная зависимость ($a=0.5$) ---

	Критерий	Коэфф. (Без)	H0 (Без)	Коэфф. (Выбросы)	H0 (Выбросы)	Изменение %
0	Пирсон	0.4110	Отвергается	0.1094	Отвергается	-73.4
1	Спирмен	0.3793	Отвергается	0.3744	Отвергается	-1.3
2	Кендалл	0.2580	Отвергается	0.2549	Отвергается	-1.2

--- Кубическая зависимость ---

	Критерий	Коэфф. (Без)	H0 (Без)	Коэфф. (Выбросы)	H0 (Выбросы)	Изменение %
0	Пирсон	-0.0223	Не отвергается	-0.0210	Не отвергается	-5.8
1	Спирмен	-0.0500	Не отвергается	-0.0515	Не отвергается	3.0
2	Кендалл	-0.0346	Не отвергается	-0.0356	Не отвергается	2.9

Влияние выбросов (Анализ робастности)

- **Линейная зависимость ($a = 0.5$):** * Коэффициент Пирсона оказался крайне чувствительным: при добавлении всего нескольких аномальных точек его значение резко падает (на **70-80%**), что может привести к ложному выводу об отсутствии связи ($p\text{-value} > 0.05$).
 - **Ранговые коэффициенты (Спирмен и Кендалл)** продемонстрировали высокую **робастность** (устойчивость). Их значения изменились незначительно (менее 2%), так как они оперируют рангами, а не абсолютными величинами.
- **Кубическая зависимость:** * Влияние выбросов на коэффициент Пирсона здесь минимально (изменение около **5-6%**). Это объясняется тем, что из-за сильного зашумления выборки переменной Z линейная связь изначально отсутствовала ($r \approx 0$). Выбросы в данном случае просто смешиваются с общим фоновым шумом, не меняя статистическую картину — связь остается незначимой для всех критериев.

```
In [ ]: sns.set_theme(style="whitegrid")

def plot_lab3_visuals(x, y_dict):
    fig, axes = plt.subplots(2, 2, figsize=(15, 12))

    # Линейная (без выбросов)
    sns.scatterplot(x=x, y=y_dict['Linear (a=0.5)'], ax=axes[0, 0], alpha=0.5)
    axes[0, 0].set_title("Линейная зависимость (a=0.5) без выбросов")
```

```

# Линейная (с выбросами)
sns.scatterplot(x=x, y=y_dict['Linear (a=0.5) + Outliers'], ax=axes[0, 1], a
axes[0, 1].set_title("Линейная зависимость (a=0.5) с выбросами")

# Кубическая
sns.scatterplot(x=x, y=y_dict['Cubic'], ax=axes[1, 0], alpha=0.5, color='gre
axes[1, 0].set_title("Кубическая зависимость")

# Квадратичная
sns.scatterplot(x=x, y=y_dict['Quadratic'], ax=axes[1, 1], alpha=0.5, color=
axes[1, 1].set_title("Квадратичная зависимость")

plt.suptitle("Визуализация исследуемых зависимостей", fontsize=16)
plt.tight_layout(rect=[0, 0.03, 1, 0.95])
plt.show()

scenarios = ['Linear (a=0.5)', 'Linear (a=0.5) + Outliers', 'Cubic', 'Quadra
metrics = []


for sc in scenarios:
    if sc in y_dict:
        r_p, _ = stats.pearsonr(x, y_dict[sc])
        r_s, _ = stats.spearmanr(x, y_dict[sc])
        r_k, _ = stats.kendalltau(x, y_dict[sc])
        metrics.append({'Сценарий': sc, 'Пирсон': r_p, 'Спирмен': r_s, 'Кенд

df_plot = pd.DataFrame(metrics).set_index('Сценарий')

df_plot.plot(kind='bar', figsize=(12, 6), rot=15)
plt.title("Сравнение коэффициентов корреляции по типам зависимостей")
plt.ylabel("Значение коэффициента")
plt.axhline(0, color='black', linewidth=0.8)
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout()
plt.show()

```

```
plot_lab3_visuals(X, Y_cases)
```



Выводы по лабораторной работе №3

В ходе лабораторной работы было проведено исследование трех коэффициентов корреляции - **Пирсона**, **Спирмена** и **Кендалла** - в различных условиях зависимости и при наличии аномальных значений.

Основные итоги:

1. Эффективность методов:

- **Коэффициент Пирсона** идеально подходит для обнаружения строго линейных зависимостей в «чистых» данных, но теряет свою эффективность

при малейших отклонениях от линейности.

- **Ранговые коэффициенты (Спирмен, Кендалл)** являются более универсальными, так как успешно фиксируют любые монотонные зависимости (например, кубическую), даже если они не являются линейными.

2. Робастность (устойчивость):

- Эксперимент с выбросами показал, что **коэффициент Пирсона крайне неустойчив**: наличие всего 0.5% аномальных точек приводит к резкому падению его значения (до 70–80%), что может привести к ложноотрицательному результату теста на значимость.
- **Коэффициенты Кендалла и Спирмена обладают высокой робастностью**, сохраняя стабильные значения (изменение < 6%) при наличии выбросов, что делает их предпочтительными для анализа реальных данных.

3. Ограничения корреляционного анализа:

- Анализ квадратичной зависимости подтвердил, что классические коэффициенты корреляции «слепы» к немонотонным связям. Нулевые значения коэффициентов при наличии явной функциональной связи ($Y = X^2 + Z$) доказывают, что **отсутствие корреляции не означает отсутствия зависимости**.