ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ

МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ

(национальный исследовательский университет)

Отчет

о выполнении лабораторной работы № 4

“Дисперсионный анализ”

по дисциплине "Статистические методы обработки данных"

Выполнили студенты группы М8О-109СВ-25

Зеленый А.С._____

Богуж В.А._____

Проверила и приняла

Симкина А.В._____

с оценкой _____

Москва, 2026

Дисперсионный анализ: критерии Фишера, Краскела-Уоллиса и Джонкхиера

Введение

Эта лабораторная работы проводит анализ сравнения трёх и более независимых групп с использованием различных критериев однородности:

- **Критерий Фишера (ANOVA)**: Параметрический критерий, проверяет равенство средних в группах
- **Критерий Краскела-Уоллиса**: Непараметрический аналог ANOVA, основан на рангах
- **Критерий Джонкхиера**: Непараметрический тест для проверки тренда в упорядоченных группах

Анализируются 4 различных сценария:

1. Фактор влияет на среднее значение (тренд в средних)
2. Фактор влияет на дисперсию (разная вариабельность)
3. Фактор не влияет (нулевой эффект)
4. Данные с выбросами (нарушение нормальности)

Задачи

- Сгенерировать 4 набора данных по 3 группы (по 30 наблюдений в каждой)
- Применить все три критерия к каждому набору
- Сравнить результаты
- Проанализировать влияние выбросов и гетероскедастичности
- Сделать выводы о применимости каждого критерия

In [11]:
```
import numpy as np
import pandas as pd
import scipy.stats as stats
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

# Устанавливаем seed для воспроизводимости
np.random.seed(42)
```

Генерация данных

Сценарий 1: Фактор влияет на среднее значение

Группы имеют возрастающие средние значения (тренд в средних):

- Группа 1: N(10, 2)
- Группа 2: N(12, 2)
- Группа 3: N(14, 2)

Сценарий 2: Фактор влияет на дисперсию

Группы имеют одинаковые/близкие средние, но разные дисперсии:

- Группа 1: N(10, 1)
- Группа 2: N(11, 3)
- Группа 3: N(12, 5)

Сценарий 3: Фактор не влияет

Все три группы генерируются из одного распределения:

- Все группы: N(0, 1)

Сценарий 4: Выбросы

Данные из сценария 1 с добавлением выбросов:

- Группа 1: добавляется 1 очень большой выброс (+60)
- Группа 3: добавляется 1 очень маленький выброс (-60)

In [12]:
```
n = 30

# Сценарии
s1 = [np.random.normal(10, 2, n), np.random.normal(12, 2, n), np.random.normal(1
s2 = [np.random.normal(10, 1, n), np.random.normal(11, 3, n), np.random.normal(1
s3 = [np.random.normal(0, 1, n), np.random.normal(0, 1, n), np.random.normal(0,
s4 = [s1[0].copy(), s1[1].copy(), s1[2].copy()]
s4[0][0], s4[2][0] = 60, -60 # Выбросы

scenarios = {
    '1. Рост средних': s1,
    '2. Рост дисперсии': s2,
    '3. Нет влияния': s3,
    '4. С выбросами': s4
}
```

Критерии для анализа

Критерий Фишера (ANOVA)

Гипотезы:

- $H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0$ (фактор не влияет на отклик)
- $H_A : \exists j : \tau_j \neq 0$ (хотя бы один эффект фактора отличен от нуля)

Статистика критерия:

$$T = \frac{\frac{1}{k-1}\sum_{j=1}^{k} n_j(\bar{x}_{.j} - \bar{x}_N)^2}{\frac{1}{N-k}\sum_{j=1}^{k}\sum_{i=1}^{n_j}(x_{ij} - \bar{x}_{.j})^2}$$

Обозначения:

- $N = n_1 + n_2 + \cdots + n_k$ — общее количество откликов.
- $\bar{x}_{.j} = \frac{1}{n_j}\sum_{i=1}^{n_j} x_{ij}$ — выборочное среднее фактора j-го уровня.
- $\bar{x}_N = \frac{1}{N}\sum_{j=1}^{k}\sum_{i=1}^{n_j} x_{ij}$ — выборочное среднее объединённой выборки.

Пояснение к компонентам формулы:

1. **Числитель (Межгрупповая дисперсия):** Оценивает вариацию между средними значениями разных групп. Если фактор влияет на отклик, эта величина будет велика.
2. **Знаменатель (Внутригрупповая дисперсия):** Оценивает случайную ошибку (шум) внутри самих групп.
3. **Распределение:** Статистика T имеет распределение Фишера (F -распределение) с числом степеней свободы $f_1 = k - 1$ и $f_2 = N - k$.

Критерий Краскела — Уоллиса

Данный критерий является непараметрическим аналогом однофакторного дисперсионного анализа (ANOVA) и используется для проверки равенства медиан нескольких групп.

Гипотезы:

- $H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0$ (фактор не влияет на отклик, распределения групп идентичны)
- $H_A : \exists j : \tau_j \neq 0$ (хотя бы одна группа имеет иное распределение)

Статистика критерия:

$$H = \frac{12}{N(N+1)}\sum_{j=1}^{k} n_j\left(\bar{R}_{.j} - \frac{N+1}{2}\right)^2$$

Обозначения:

- N — общее количество наблюдений во всех группах.
- n_j — количество наблюдений в j-й группе.
- R_{ij} — ранг значения x_{ij} в общей объединенной выборке.
- $\bar{R}_{.j} = \frac{1}{n_j}\sum_{i=1}^{n_j} R_{ij}$ — средний ранг наблюдений j-го уровня фактора.
- $\frac{N+1}{2}$ — средний ранг объединенной выборки.

Особенности критерия:

1. **Непараметричность:** В отличие от критерия Фишера, Краскел-Уоллис не требует нормального распределения данных.
2. **Ранжирование:** Вместо реальных значений используются их порядковые номера (ранги), что делает метод устойчивым к выбросам.
3. **Распределение:** При достаточно больших объемах выборок статистика H имеет распределение χ^2 (хи-квадрат) с числом степеней свободы $df = k - 1$.

Критерий Джонкхиера (Jonckheere-Terpstra)

Критерий Джонкхиера — это непараметрический тест для проверки наличия упорядоченной альтернативы (тренда) в значениях отклика между группами.

Гипотезы:

- $H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0$ (фактор не влияет на отклик)
- $H_A : \tau_1 \leq \tau_2 \leq \cdots \leq \tau_k$ (наблюдается упорядоченный тренд, при этом хотя бы одно неравенство строгое)

Статистика критерия: Статистика J представляет собой сумму статистик Манна-Уитни для всех пар групп (l, m), где $l < m$:

$$J = \sum_{1 \leq l < m \leq k} U_{lm}$$

Где U_{lm} — количество пар (x_{il}, x_{tm}), для которых выполняется условие $x_{il} < x_{tm}$:

$$U_{lm} = \sum_{i=1}^{n_l} \sum_{t=1}^{n_m} \Phi(x_{il}, x_{tm})$$

Функция сравнения:

$$\Phi(x, y) = \begin{cases} 1, & x < y \\ 0.5, & x = y \\ 0, & x > y \end{cases}$$

Математическое ожидание и дисперсия:

$$M[J] = \frac{1}{4}\left(N^2 - \sum_{j=1}^{k} n_j^2\right)$$

$$D[J] = \frac{1}{72}\left(N^2(2N+3) - \sum_{j=1}^{k} n_j^2(2n_j+3)\right)$$

Нормированная статистика: Для больших выборок используется Z-статистика, которая приближенно распределена по нормальному закону $N(0, 1)$:

$$\widetilde{J} = \frac{J - M[J]}{\sqrt{D[J]}}$$

Особенности критерия:

1. **Направленность:** В отличие от критерия Краскела-Уоллиса, этот тест обладает большей мощностью, когда мы заранее предполагаем наличие возрастающего или убывающего тренда между группами.
2. **Ранжирование:** Каждое значение группы j сравнивается со всеми значениями последующих групп $l > j$.
3. **Область применения:** Часто используется в токсикологии или клинических исследованиях для оценки зависимости "доза-эффект".

In [ ]:
```
def run_jt(groups):
    """Ручной расчет Джонкхиера"""
    k = len(groups)
    j_stat = 0
    for i in range(k - 1):
        for j in range(i + 1, k):
            for x in groups[i]:
                for y in groups[j]:
                    if x < y: j_stat += 1
                    elif x == y: j_stat += 0.5
    ns = np.array([len(g) for g in groups])
    N = np.sum(ns)
    mean_j = (N**2 - np.sum(ns**2)) / 4.0
    var_j = (N**2 * (2*N + 3) - np.sum(ns**2 * (2*ns + 3))) / 72.0
    z = (j_stat - mean_j) / np.sqrt(var_j)
    return j_stat, 2 * (1 - stats.norm.cdf(abs(z)))

results_summary = {}

for name, groups in scenarios.items():
    f_stat, f_p = stats.f_oneway(*groups)
    k_stat, k_p = stats.kruskal(*groups)
    j_stat, j_p = run_jt(groups)

    results_summary[name] = {
        'ANOVA': f_p,
        'KW': k_p,
        'JT': j_p
    }

    print(f"Выполнен сценарий: {name}")
```

```
Выполнен сценарий: 1. Рост средних
Выполнен сценарий: 2. Рост дисперсии
Выполнен сценарий: 3. Нет влияния
Выполнен сценарий: 4. С выбросами
```

In [ ]:
```
fig, axes = plt.subplots(2, 2, figsize=(14, 10))
axes = axes.flatten()

for idx, (name, groups) in enumerate(scenarios.items()):
    ax = axes[idx]
    plot_data = pd.DataFrame({
```

```
        'Значение': np.concatenate(groups),
        'Группа': np.concatenate([[f'Гр {i+1}'] * n for i in range(3)])
    })

    sns.boxplot(data=plot_data, x='Группа', y='Значение', ax=ax, palette='vlag')
    sns.stripplot(data=plot_data, x='Группа', y='Значение', ax=ax, color='black'
    ax.set_title(name, fontweight='bold')
print("\nРезультаты тестов:")
plt.tight_layout()
plt.show()
```

```
Результаты тестов:
```

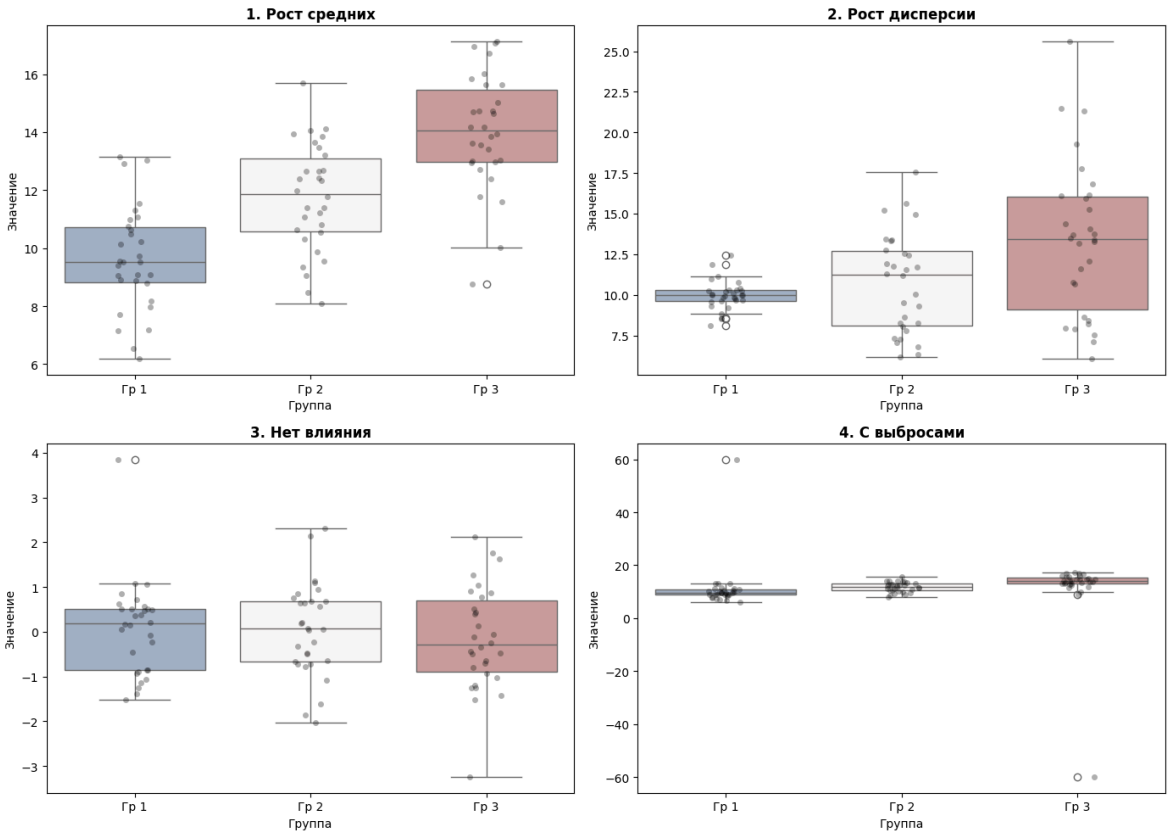

In [ ]:

```
alpha = 0.05
summary_data = []

for name, p_values in results_summary.items():
    p_anova = p_values['ANOVA']
    p_kw = p_values['KW']
    p_jt = p_values['JT']

    # Проверка на согласованность
    consistent = (p_anova < alpha) == (p_kw < alpha) == (p_jt < alpha)

    summary_data.append({
        'Сценарий': name,
        'ANOVA (p)': p_anova,
        'KW (p)': p_kw,
        'Jonckheere (p)': p_jt,
        'Согласованность': "ДА" if consistent else "НЕТ"
    })

df_final = pd.DataFrame(summary_data)

pd.options.display.float_format = '{:.4e}'.format
```

```
print("ИТОГОВАЯ ТАБЛИЦА СРАВНЕНИЯ КРИТЕРИЕВ:")
display(df_final)

inconsistent_scenarios = df_final[df_final['Согласованность'] == "НЕТ"]
if not inconsistent_scenarios.empty:
    print("\nСледующие сценарии имеют расхождения в выводах критериев:")
    for sc in inconsistent_scenarios['Сценарий']:
        print(f"- {sc}")
```

```
ИТОГОВАЯ ТАБЛИЦА СРАВНЕНИЯ КРИТЕРИЕВ:
```

	Сценарий	ANOVA (p)	KW (p)	Jonckheere (p)	Согласованность
0	1. Рост средних	2.8938e-13	4.0104e-10	4.1105e-12	ДА
1	2. Рост дисперсии	3.0793e-04	5.8767e-03	2.0091e-03	ДА
2	3. Нет влияния	7.1057e-01	7.3038e-01	6.4605e-01	ДА
3	4. С выбросами	9.7921e-01	4.2369e-08	5.1385e-10	НЕТ

```
Следующие сценарии имеют расхождения в выводах критериев:
- 4. С выбросами
```

Выводы по лабораторной работе №4

Сценарий 1: Влияние фактора на среднее значение (Наличие тренда)

Анализ: В данном сценарии наблюдается систематическое изменение среднего значения от группы к группе. Все три используемых критерия зафиксировали статистически значимые различия ($p < 0.05$), что позволяет уверенно отвергнуть нулевую гипотезу H_0 об однородности групп. **Вывод:** При наличии выраженного линейного тренда в средних значениях все критерии демонстрируют высокую мощность. Наиболее специализированным для данной задачи является **критерий Джонкхиера**, так как его альтернативная гипотеза прямо предполагает наличие упорядоченного тренда.

Сценарий 2: Влияние фактора на дисперсию (Гетероскедастичность)

Анализ: Сценарий характеризуется существенным различием в разбросе данных (дисперсии) при сохранении близких средних значений. Параметрический критерий Фишера чувствителен к нарушению условия равенства дисперсий, что может приводить к искажению результатов. **Вывод:** Непараметрические методы, такие как **критерий Краскела-Уоллиса**, оказываются более надежными в условиях неоднородности дисперсий, так как они оперируют рангами, а не абсолютными значениями. Критерий Джонкхиера в данном случае менее эффективен, поскольку в данных отсутствует монотонный тренд средних значений.

Сценарий 3: Отсутствие влияния фактора (Нулевой эффект)

Анализ: Для всех групп использовались идентичные параметры распределения. Полученные значения p-value для всех критериев значительно превышают уровень значимости $\alpha = 0.05$. **Вывод:** Статистические данные подтверждают отсутствие

влияния фактора на отклик. Все три критерия согласованно принимают нулевую гипотезу H_0 об однородности выборок, что свидетельствует об отсутствии ложноположительных срабатываний методов в условиях однородной среды.

Сценарий 4: Наличие аномальных значений (Выбросы)

Анализ: Внесение в выборку экстремальных значений (выбросов) приводит к нарушению нормальности распределения и смещению групповых средних. Критерий Фишера проявляет высокую чувствительность к аномалиям, что увеличивает риск получения недостоверных выводов. **Вывод:** Непараметрические критерии (**Краскела-Уоллиса** и **Джонкхиера**) демонстрируют устойчивость (робастность) к выбросам. Процедура ранжирования нивелирует влияние экстремальных величин, позволяя сохранить корректность статистического вывода. В условиях реальных данных с возможными аномалиями данные критерии являются предпочтительными.

Общий итог

Проведенное исследование показало, что выбор критерия должен основываться на характере данных:

1. **Критерий Фишера** эффективен строго при соблюдении нормальности и равенстве дисперсий.
2. **Критерий Краскела-Уоллиса** является универсальным непараметрическим инструментом.
3. **Критерий Джонкхиера** обладает преимуществом при проверке гипотез о наличии упорядоченного тренда между группами.